

Analisi e Predizione dei Consumi Energetici

Progetto di Data Analytics End-to-End

Rei Mici

0001177723 / Tecnologie dei Sistemi Informatici

Anno Accademico 2025/2026

Indice

1	Introduzione e Obiettivo di Business	2
1.1	Lo Scenario	2
1.2	L'Obiettivo del Progetto	2
2	Data Engineering e Preprocessing	3
2.1	Il Dataset	3
2.2	Data Cleaning: Il problema dei Duplicati Temporali	3
2.3	Feature Engineering	3
3	Analisi Esplorativa (EDA)	4
3.1	Trend e Stagionalità	4
3.2	Profilo Orario:	4
4	Segmentazione (Clustering)	5
5	Modello Predittivo e Risultati	6
5.1	Architettura del Modello	6
5.2	Performance e Metriche	6
5.2.1	1. Affidabilità sui Giorni Miti (Recall: 80%)	6
5.2.2	2. Precisione sui Giorni Critici (Precision: 75%)	6
5.2.3	3. Il Limite della Recall Critica (64%)	6
6	Conclusioni	8
6.1	Sintesi Finale	8

Capitolo 1

Introduzione e Obiettivo di Business

1.1 Lo Scenario

Immaginiamo di lavorare per una grande azienda di distribuzione elettrica (Utility). La gestione della rete elettrica è una sfida di equilibrio costante: l'energia non può essere immagazzinata facilmente in grandi quantità, quindi deve essere prodotta (o acquistata) nello stesso istante in cui viene consumata.

L'azienda ha un problema critico: la domanda di energia è volatile e dipende fortemente dal clima. Questo crea due scenari di rischio opposti:

- **Sottostima della Domanda:** Se la richiesta supera l'offerta prevista, si rischia il sovraccarico della rete e, nel peggiore dei casi, il **Blackout**.
- **Sovrastima della Domanda:** Se l'azienda attiva centrali di riserva prevedendo un picco che non avviene, genera uno **Spreco Economico** (costi di carburante, personale, usura impianti) e ambientale inutile.

1.2 L'Obiettivo del Progetto

In questo elaborato analizzeremo 14 anni di dati storici reali (2004-2018) relativi a una rete regionale con l'obiettivo di:

1. **Capire:** Identificare i pattern di consumo (Trend, Stagionalità, Orari Critici).
2. **Segmentare:** Suddividere le giornate operative in livelli di rischio (Clustering).
3. **Prevedere:** Creare un modello di Machine Learning in grado di anticipare, basandosi solo sul calendario, se il giorno successivo sarà a rischio critico.

Capitolo 2

Data Engineering e Preprocessing

2.1 Il Dataset

Il punto di partenza è un dataset minimalista composto da due sole colonne:

- **Datetime:** Timestamp orario.
- **AEP_MW:** Consumo energetico rilevato in Megawatt.

Nonostante la semplicità apparente, il dataset contiene oltre 120.000 osservazioni.

2.2 Data Cleaning: Il problema dei Duplicati Temporali

Durante la fase di analisi preliminare, è emersa una criticità legata alla natura stessa del tempo civile: il cambio dell'ora legale. Ogni anno, in autunno, le lancette vengono spostate indietro, portando alla registrazione doppia della stessa ora (es. l'ora 02:00 viene registrata due volte). **Soluzione:** È stata implementata una pipeline di pulizia per rimuovere i duplicati mantenendo la prima occorrenza, garantendo così la continuità sequenziale della serie storica necessaria per l'analisi.

2.3 Feature Engineering

Per trasformare una serie temporale in un problema di apprendimento supervisionato, abbiamo estratto nuove variabili (Feature) dalla data:

- **Mese e Anno:** Per catturare stagionalità e trend.
- **Giorno della Settimana:** Per distinguere giorni lavorativi dai weekend.
- **Ora del Giorno:** Fondamentale per l'analisi dei picchi giornalieri.

Capitolo 3

Analisi Esplorativa (EDA)

3.1 Trend e Stagionalità

L'analisi di decomposizione della serie storica ha evidenziato un fenomeno interessante: il *Disaccoppiamento*. Nonostante la crescita economica, il consumo energetico medio negli anni è rimasto stabile o in lieve calo. Questo suggerisce che l'efficientamento energetico (es. LED, isolamento termico) sta compensando l'aumento dei dispositivi elettronici.

3.2 Profilo Orario:

Confrontando il profilo di consumo medio orario tra Estate e Inverno, abbiamo identificato la radice del rischio blackout.

- **Inverno:** Il consumo ha due picchi (mattina e sera), legati all'illuminazione e al riscaldamento. Il carico è alto ma costante.
- **Estate:** Il consumo presenta un singolo, violento picco tra le **14:00** e le **18:00**.

Insight Operativo

Il rischio maggiore per la rete risiede nei pomeriggi estivi, quando la coincidenza tra picco solare e uso massiccio dei condizionatori spinge la domanda a livelli estremi (> 20.000 MW).

Capitolo 4

Segmentazione (Clustering)

Per semplificare la complessità dei dati orari, abbiamo applicato un algoritmo di apprendimento non supervisionato, il **K-Means**, per raggruppare le giornate in categorie omogenee. L'analisi ha identificato **3 Cluster Operativi**:

1. **Cluster Mite (Mezze Stagioni)**: Basso consumo e bassa variabilità. Sono i giorni ideali per programmare la manutenzione.
2. **Cluster Standard (Inverno)**: Consumo medio-alto ma prevedibile.
3. **Cluster Critico (Estate)**: Giornate caratterizzate da picchi estremi e alta volatilità. Queste sono le giornate "Bollino Rosso" da monitorare.

Capitolo 5

Modello Predittivo e Risultati

5.1 Architettura del Modello

L'obiettivo finale era prevedere la classe di rischio (Mite, Standard, Critico) del futuro usando **solo** le informazioni del calendario. È stato scelto un classificatore **Random Forest** (trainato sull'80% dei dati e testato sul 20%), utilizzando come input esclusivamente: Mese, Giorno della Settimana e Anno.

5.2 Performance e Metriche

Il modello ha raggiunto un'**Accuratezza Globale del 74%**. Analizziamo nel dettaglio cosa significa questo numero per il business:

5.2.1 1. Affidabilità sui Giorni Miti (Recall: 80%)

Il modello riconosce con grande precisione i giorni tranquilli. **Impatto:** L'azienda può pianificare le interruzioni per manutenzione con un margine di sicurezza molto alto, sapendo che il rischio di un picco imprevisto è minimo.

5.2.2 2. Precisione sui Giorni Critici (Precision: 75%)

Quando il modello lancia un "Allarme Rosso" (prevede un giorno Critico), ha ragione 3 volte su 4. **Impatto:** I "Falsi Positivi" sono bassi. Se attiviamo le centrali di riserva basandoci sul modello, raramente sprechiamo soldi inutilmente.

5.2.3 3. Il Limite della Recall Critica (64%)

Il modello riesce a identificare circa il 64% dei giorni critici totali, "perdendone" il 36%. **Analisi della Causa:** Questo gap non è un errore del codice, ma un limite fisico dei dati. Il modello usa solo il calendario. Il calendario sa che a Luglio *solitamente* fa caldo, ma non può sapere se uno specifico 15 Luglio ci sarà un temporale o un'ondata di calore

record. Quella variabilità del 36% dipende dal **Meteo puntuale**, che non è presente in questo dataset.

Capitolo 6

Conclusioni

Il risultato più sorprendente di questa analisi non risiede solo nei numeri finali, ma nel percorso compiuto. Siamo partiti da un dataset estremamente minimalista, composto da due sole colonne grezze: `Datetime` e `AEP_MW`. Senza dati meteo, senza dati economici e senza informazioni sui clienti, abbiamo applicato tecniche di Data Engineering per estrarre valore strategico.

6.1 Sintesi Finale

L'accuratezza del **74%** ottenuta con sole variabili di calendario ci insegna una lezione fondamentale: **quasi tre quarti del comportamento energetico umano sono dettati puramente dalle abitudini sociali e dalla stagionalità.**

Abbiamo dimostrato che è possibile costruire un sistema di supporto decisionale solido anche con risorse informative minime.